
Analyse Factorielle des Correspondances

Présenté par :

- SADIK Mohammed
- NOUGBOLO Godwin Elie

Encadrer Par :

- Prof AGHRICH Ahmed

Définition de l'AFC

L'Analyse Factorielle des Correspondances (AFC) est une méthode statistique exploratoire qui permet de visualiser et d'interpréter les associations entre deux variables qualitatives à partir d'un tableau de contingence. Elle est l'équivalent de l'ACP pour les variables qualitatives.

	ACP	AFC
Type de données	Quantitatives	Qualitatives
Structure	Individus $\times$ variables	Tableau de contingence
Objectif	Réduire les dimensions	Visualiser les associations
Distance utilisée	Distance euclidienne	Distance du χ^2
Résultat final	Biplot	Biplot

Étape 1 — Construction du tableau de contingence

POURQUOI C'EST IMPORTANT ?

C'est le point de départ de toute l'analyse. Sans ce tableau, on ne peut rien faire.

Si ce tableau est mal construit, toute la suite sera fausse.

On croise deux variables qualitatives A et B dans un tableau. Chaque case n_{ij} représente le nombre de personnes ayant simultanément la modalité **i** de A et la modalité **j** de B. Les lignes correspondent aux modalités de A, les colonnes à celles de B.

On calcule les totaux marginaux de chaque ligne, de chaque colonne, et le total général n.

	Sport	Cinéma	Lecture
Étudiant	30	50	20
Salarié	60	20	40
Retraité	10	15	55

Étape 2 — Calcul des fréquences relatives et des marges

POURQUOI C'EST IMPORTANT ?

Cette étape permet de comparer les groupes de manière juste, même s'ils n'ont pas la même taille. On transforme les chiffres bruts en proportions.

On divise chaque chiffre du tableau par le total n pour obtenir une fréquence relative

$$f_{ij} = \frac{n_{ij}}{n}$$


On calcule également les marges :

- Marge Ligne : $f_{i.} = \sum_j f_{ij} \rightarrow$ *proportion de personnes dans le groupe i .*
- Marge Colonne : $f_{.j} = \sum_i f_{ij} \rightarrow$ *proportion de personnes dans le groupe j .*

➔ Ces marges représentent le poids de chaque modalité dans l'analyse.

Étape 2 — Calcul des fréquences relatives et des marges - **Exemple**

	Sport	Cinéma	Lecture	Total
Étudiant	30	50	20	100
Salarié	60	20	40	120
Retraité	10	15	55	80
Total	100	85	115	300



	Sport	Cinéma	Lecture	Marge $f_{i.}$
Étudiant	$\frac{30}{300} = 0,100$	$\frac{50}{300} = 0,167$	$\frac{20}{300} = 0,067$	0,333
Salarié	$\frac{60}{300} = 0,200$	$\frac{20}{300} = 0,067$	$\frac{40}{300} = 0,133$	0,400
Retraité	$\frac{10}{300} = 0,033$	$\frac{15}{300} = 0,050$	$\frac{55}{300} = 0,183$	0,267
Marge $f_{.j}$	0,333	0,283	0,383	1,000

Étape 3 — Calcul des profils lignes et colonnes

POURQUOI C'EST IMPORTANT ?

C'est le cœur de l'AFC. Les profils permettent de décrire le comportement d'un groupe en termes de distribution relative et de le comparer à la distribution globale

Profil ligne de la ligne i : on divise chaque cellule de la ligne par sa marge.

$$\text{Profil ligne} = \frac{f_{ij}}{f_{i.}}$$

Profil Colonne de la ligne j : on divise chaque cellule de la colonne par sa marge.

$$\text{Profil Colonne} = \frac{f_{ij}}{f_{.j}}$$

Étape 3 — Calcul des profils lignes et colonnes - **Exemple**

	Sport	Cinéma	Lecture
Étudiant	$\frac{30}{100} = 0,30$	$\frac{50}{100} = 0,50$	$\frac{20}{100} = 0,20$
Salarié	$\frac{60}{120} = 0,50$	$\frac{20}{120} = 0,17$	$\frac{40}{120} = 0,33$
Retraité	$\frac{10}{80} = 0,13$	$\frac{15}{80} = 0,19$	$\frac{55}{80} = 0,69$

Retraité :

- Lecture = 69% → Lecture dominante
- peu de Sport (13%)

Retraité = Aime Beaucoup la Lecture

Étudiant :

- Cinéma = 50% → dominante
- Sport = 30 % important
- Lecture Moyenne (20%)

Étudiant = **Sport + Cinéma**

Étape 4 — Calcul du χ^2 et de l'inertie totale

POURQUOI C'EST IMPORTANT ?

On doit vérifier qu'il existe vraiment un lien entre les deux variables. Si les variables sont indépendantes, l'AFC n'a aucun sens.

On calcule les effectifs théoriques — ce qu'on observerait si les variables étaient indépendantes :

$$e_{ij} = \frac{n_{i.} \times n_{.j}}{n}$$

	Sport	Cinéma	Lecture
Étudiant	$\frac{100 \times 100}{300} = 33,3$	$\frac{100 \times 85}{300} = 28,3$	$\frac{100 \times 115}{300} = 38,3$
Salarié	$\frac{120 \times 100}{300} = 40,0$	$\frac{120 \times 85}{300} = 34,0$	$\frac{120 \times 115}{300} = 46,0$
Retraité	$\frac{80 \times 100}{300} = 26,7$	$\frac{80 \times 85}{300} = 22,7$	$\frac{80 \times 115}{300} = 30,7$

Étape 4 — Calcul du χ^2 et de l'inertie totale

On calcule le χ^2 qui mesure l'écart entre les effectifs observés et théoriques :

$$\chi^2 = \sum_{i,j} \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

L'inertie totale normalise le χ^2 pour comparer des tableaux de tailles différentes : $\text{Inertie} = \frac{\chi^2}{n}$

	Sport	Cinéma	Lecture
Étudiant	$\frac{(30-33,3)^2}{33,3} = 0,33$	$\frac{(50-28,3)^2}{28,3} = 16,58$	$\frac{(20-38,3)^2}{38,3} = 8,77$
Salarié	$\frac{(60-40)^2}{40} = 10,00$	$\frac{(20-34)^2}{34} = 5,76$	$\frac{(40-46)^2}{46} = 0,78$
Retraité	$\frac{(10-26,7)^2}{26,7} = 10,42$	$\frac{(15-22,7)^2}{22,7} = 2,60$	$\frac{(55-30,7)^2}{30,7} = 19,24$

$\chi^2 = 0,33 + 16,58 + 8,77 + 10,00 + 5,76 + 0,78 + 10,42 + 2,60 + 19,24 = 74,48$ **Inertie** $= \frac{\chi^2}{300} = 0,248$

➔ L'inertie de 0,248 confirme un lien fort entre la catégorie et le loisir.

Étape 5 — Décomposition en valeurs propres

POURQUOI C'EST IMPORTANT ?

C'est ici qu'on prépare le graphique final. On cherche les axes qui vont permettre de visualiser les données. Chaque axe capture une partie du lien : le premier axe capture la plus grande partie, le deuxième le reste.

Construire la matrice S des résidus :

Chaque élément de S mesure l'écart entre ce qu'on observe et ce qu'on attendrait sans lien, normalisé par les marges :

$$S_{ij} = \frac{f_{ij} - f_{i.} \times f_{.j}}{\sqrt{f_{i.} \times f_{.j}}}$$

Étape 5 — Décomposition en valeurs propres - Exemple

	Sport	Cinéma	Lecture	Marge f_i
Étudiant	$\frac{30}{300} = 0,100$	$\frac{50}{300} = 0,167$	$\frac{20}{300} = 0,067$	0,333
Salarié	$\frac{60}{300} = 0,200$	$\frac{20}{300} = 0,067$	$\frac{40}{300} = 0,133$	0,400
Retraité	$\frac{10}{300} = 0,033$	$\frac{15}{300} = 0,050$	$\frac{55}{300} = 0,183$	0,267
Marge f_j	0,333	0,283	0,383	1,000

Données Initials

	Sport	Cinéma	Lecture
Étudiant	$\frac{100 \times 100}{300} = 33,3$	$\frac{100 \times 85}{300} = 28,3$	$\frac{100 \times 115}{300} = 38,3$
Salarié	$\frac{120 \times 100}{300} = 40,0$	$\frac{120 \times 85}{300} = 34,0$	$\frac{120 \times 115}{300} = 46,0$
Retraité	$\frac{80 \times 100}{300} = 26,7$	$\frac{80 \times 85}{300} = 22,7$	$\frac{80 \times 115}{300} = 30,7$

Données Attendu

$S =$

	Sport	Cinéma	Lecture
Étudiant	-0,033	+0,235	-0,171
Salarié	+0,183	-0,139	-0,051
Retraité	-0,187	-0,093	+0,254

Étape 5 — Décomposition en valeurs propres - **Exemple**

Résolution de $\det(S - \lambda I) = 0$

Les Solutions :

$$\lambda_1 = 0,157 \quad \lambda_2 = 0,092$$

$$**Inertie Total** = $\lambda_1 + \lambda_2$ = **Inertie** = 0,248$$

Axe	Valeur Propre	Inertie Expliquée
Axe 1	0,157	63 %
Axe 2	0,092	37 %
Total	0,248	100 %

$$Inertie\ expliquée(axe\ i) = \frac{\lambda_i}{\sum_i \lambda_i}$$

Étape 6 — Calcul des coordonnées factorielles

POURQUOI C'EST IMPORTANT ?

Les valeurs propres nous ont dit combien d'information chaque axe explique. Maintenant on a besoin de savoir où placer chaque modalité sur ces axes. Les coordonnées sont les positions des modalités sur le graphique final.

Pour chaque axe k , on résout le système linéaire : $(S - \lambda_k \cdot I) \cdot v_k = 0$

La solution v_k est le vecteur propre associé à λ_k

$$v_1 = \begin{pmatrix} -0.3563 \\ -0.5179 \\ 0.7776 \end{pmatrix} \quad v_2 = \begin{pmatrix} -0.7353 \\ 0.6687 \\ 0.1100 \end{pmatrix}$$

Étape 6 — Calcul des coordonnées factorielles

MAIS COMMENT FAIRE LA PROJECTIONS ???

$$F_{ik} = \frac{\text{profil}_i \times v_k}{\sqrt{\lambda_k}}$$

Coordonnées des LIGNES

Sur l'Axe 1 :

$$\text{profil Lignes} = \begin{pmatrix} 0.30 & 0.50 & 0.20 \\ 0.50 & 0.17 & 0.33 \\ 0.13 & 0.19 & 0.69 \end{pmatrix} \times \frac{v_1}{\sqrt{\lambda_1}} = \begin{pmatrix} -0.5305 \\ -0.0134 \\ 0.9907 \end{pmatrix}$$

Étape 6 — Calcul des coordonnées factorielles

Coordonnées des LIGNES

Sur l'Axe 2 :

$$profil\ Lignes = \begin{pmatrix} 0.30 & 0.50 & 0.20 \\ 0.50 & 0.17 & 0.33 \\ 0,13 & 0.19 & 0.69 \end{pmatrix} \times \frac{v_2}{\sqrt{\lambda_2}} = \begin{pmatrix} 0.4496 \\ -0.7271 \\ 0.3614 \end{pmatrix}$$

Modalité	Axe 1	Axe 2
Étudiant	-0.53	0.4496
Salarié	-0.0134	-0.7271
Retraité	0.9907	0.3614

Étape 6 — Calcul des coordonnées factorielles

Coordonnées des COLONNES

Sur l'Axe 1 :

$$\textit{Profil Colonnes} = \begin{pmatrix} 0.30 & 0.60 & 0.10 \\ 0.588 & 0.235 & 0.176 \\ 0.174 & 0.348 & 0.478 \end{pmatrix} \times \frac{v_1}{\sqrt{\lambda_1}} = \begin{pmatrix} -0.3904 \\ -0.6076 \\ +0.6072 \end{pmatrix}$$

Sur l'Axe 2 :

$$\textit{Profil Colonnes} = \begin{pmatrix} 0.30 & 0.60 & 0.10 \\ 0.588 & 0.235 & 0.176 \\ 0.174 & 0.348 & 0.478 \end{pmatrix} \times \frac{v_2}{\sqrt{\lambda_2}} = \begin{pmatrix} -0.8822 \\ +0.6496 \\ -0.0375 \end{pmatrix}$$

Étape 6 — Calcul des coordonnées factorielles

Coordonnées des COLONNES

Modalité	Axe 1	Axe 2
Sport	-0.3904	-0.8822
Cinéma	-0.6076	+0.6496
Lecture	+0.6072	-0.0375

Étape 7 — Le Biplot (graphique final)

POURQUOI C'EST IMPORTANT ?


C'est le résultat final de toute l'analyse. C'est le graphique qui répond à la question de départ : quel groupe est associé à quel loisir ? Toutes les étapes précédentes n'avaient qu'un seul but : produire ce graphique.

On place toutes les modalités lignes et colonnes sur le même graphique. L'axe horizontal correspond à l'axe 1, l'axe vertical à l'axe 2. Un axe se lit par opposition : ce qui est à gauche s'oppose à ce qui est à droite.

Situation observée sur le graphique	Ce que cela signifie
Une catégorie proche d'un loisir	Ces deux modalités sont fortement liées
Une catégorie loin d'un loisir	Ces deux modalités ont peu de lien
Deux catégories proches l'une de l'autre	Elles ont des comportements similaires
Une modalité proche du centre	Son comportement est proche de la moyenne
Une modalité loin du centre	Son comportement est très particulier

Étape 7 — Le Biplot (graphique final)

Exemple — Schéma du biplot



Étape 8 — Qualité de représentation ($\cos^2$)

POURQUOI C'EST IMPORTANT ?

On a projeté des données complexes sur un simple graphique 2D. Certains points peuvent être mal représentés. Si on interprète un point mal représenté, on risque de faire de mauvaises conclusions. Le $\cos^2$ nous dit à qui on peut faire confiance.

On projette des données en plusieurs dimensions sur un plan 2D : on peut perdre de l'information. Le $\cos^2$ mesure la qualité de cette projection pour chaque modalité :

$$\cos_k^2(i) = \frac{(\text{coordonnée sur l'axe } k)^2}{\sum_l (\text{coordonnée sur l'axe } l)^2}$$

Étape 8 — Qualité de représentation ($\cos^2$)

Point	$\cos^2$ Axe 1	$\cos^2$ Axe 2
Étudiant	0.5820	0.4180
Salarié	0.0003	0.9997
Retraité	0.8826	0.1174
Sport	0.1638	0.8362
Cinéma	0.4667	0.5333
Lecture	0.9962	0.0038

**Merci pour votre attention,
nos chers futurs ingénieurs.**